

# Muestreo Estratificado

## Ejercicio 4<sup>\*</sup>

García Prado, Sergio  
sergio@garciparedes.me

12 de noviembre de 2017

### Resumen

En este trabajo se desarrollan las expresiones del tamaño de muestra  $n$  global para estimar la media poblacional  $\hat{\mu}$  fijado un error de estimación global  $B$  y una confianza  $(1 - \alpha)$  para *m.a.s.* con y sin reemplazamiento

## 1. Introducción

Denotaremos por  $U = U_1 \cup \dots \cup U_h \cup \dots \cup U_L = \{1, \dots, k, \dots, N\}$  a la población, para la cual tenemos una división en  $L$  estratos denotando por  $U_h$  al estrato  $h \in \{1, \dots, L\}$ . Sea  $I_h$  el conjunto de índices de las observaciones seleccionadas en el estrato  $U_h$  y  $s_h$  la muestra extraída de dicho estrato. Por tanto, podemos denotar a la muestra global por  $s = s_1 \cup \dots \cup s_h \cup \dots \cup s_L$ .

Denotaremos por  $\mathcal{T}$  al total poblacional de una determinada variable de interés  $Y$  denotando como  $y_k \quad \forall k \in U$  al  $k$ -ésimo valor de  $Y$ . Es fácil entender por tanto que el total poblacional se define como  $\mathcal{T} = \sum_U y_k$ .

Denotaremos por  $\mu$  a la media poblacional de una determinada variable de interés  $Y$  de carácter binario denotando como  $y_k \quad \forall k \in U$  al  $k$ -ésimo valor de  $Y$ . Es fácil entender por tanto que la media poblacional se define como  $\mu = \frac{\sum_U y_k}{N} = \frac{\mathcal{T}}{N}$ .

Sea  $N$  el tamaño de la población,  $N_h$  el del estrato  $U_h$  y  $n_h$  el de la muestra  $s_h$ . El tamaño relativo del estrato se define como  $W_h = \frac{N_h}{N}$ . Denotaremos por  $f_h = \frac{n_h}{N_h}$  el tamaño relativo de la muestra.

Definiremos  $n_h$  como el tamaño de la muestra  $h$ -ésima. Esto también puede entenderse como el tamaño de la muestra global ponderado por un determinado peso  $w_h$  dependiente de la estrategia de afijación escogida. Esto se puede definir matemáticamente como:

$$n_h = n * w_h \quad (1)$$

Donde  $w_h$  depende del tipo de afijación sobre el cual se esté trabajando. En las ecuaciones (2) y (3) se muestra para los casos de *afijación proporcional* y *mínima varianza* respectivamente.

$$w_h = W_h \quad (\text{afijación proporcional}) \quad (2)$$

$$w_h = \frac{N_h \sigma_h^*}{\sum_{i=1}^L N_i \sigma_i^*} \quad (\text{afijación mínima varianza}) \quad (3)$$

Para tamaños de estrato  $N_h$  grandes es fácil comprobar que se cumple la propiedad  $\frac{N_h}{N_h - 1} \simeq 1$ , lo cual permite simplificar la ecuación del tamaño de la muestra.

---

\*URL: <https://github.com/garciparedes/statistical-sampling-stratified>

Puesto que lo que se pretende demostrar en este trabajo es la ecuación para estimar el tamaño  $n$  de la muestra global, fijando un error de estimación  $B$  a un nivel de confianza  $k$ , esto es equivalente a despejar el valor  $n$  en la ecuación (4).

$$B^2 = k^2 \text{Var}(\hat{\theta}) \quad (4)$$

## 2. Demostración para *m.a.s.* sin reemplazamiento.

Bajo la hipótesis de *muestreo aleatorio simple* (*m.a.s.*), a partir del cual se pretende obtener una aproximación lo más precisa posible de la media poblacional  $\mu$ , un buen estimador del total poblacional es  $\hat{T}_{m.a.s.} = \sum_{h=1}^n \sum_{k \in s_h} \frac{y_k}{n_h} N_h$ . Para el caso del estimador de la proporción poblacional, un buen estimador es  $\hat{\mu}_{m.a.s.} = \frac{\hat{T}_{m.a.s.}}{N}$ .

En las ecuaciones (5) y (6) se definen respectivamente las varianzas del estimador del total poblacional  $\hat{T}$  así como la proporción poblacional  $\hat{\mu}$ .

$$\begin{aligned} \text{Var}(\hat{T}_{m.a.s.}) &= \\ &= \sum_{h=1}^L \frac{N_h^2 (1 - f_h) \sigma_h^{*2}}{n_h} \\ &= \sum_{h=1}^L \frac{N_h^2 (1 - \frac{n_h}{N_h}) \sigma_h^{*2}}{n_h} \\ &= \sum_{h=1}^L \frac{(N_h^2 - N_h n_h) \sigma_h^{*2}}{n_h} \\ &= \sum_{h=1}^L \left( \frac{N_h^2}{n_h} - N_h \right) \sigma_h^{*2} \end{aligned} \quad (5)$$

$$\begin{aligned} \text{Var}(\hat{\mu}_{m.a.s.}) &= \\ &= \text{Var} \left( \frac{\hat{T}_{m.a.s.}}{N} \right) \\ &= \frac{\text{Var}(\hat{T}_{m.a.s.})}{N^2} \\ &= \frac{\sum_{h=1}^L \left( \frac{N_h^2}{n_h} - N_h \right) \sigma_h^{*2}}{N^2} \\ &= \sum_{h=1}^L \left( \frac{W_h^2}{n_h} - \frac{W_h^2}{N_h} \right) \sigma_h^{*2} \end{aligned} \quad (6)$$

Para llegar a la expresión que relacione el tamaño de la muestra global  $n$  con el error de estimación  $B$  a un nivel de confianza  $(1 - \alpha)$ , definiremos  $k = Z_{1-\alpha/2}$ , siendo  $Z_{1-\alpha/2}$  el valor crítico  $(1 - \alpha/2)$  de la *distribución normal estándar*  $N(0, 1)$ . Además, nos apoyaremos en la ecuación (4) y la estimación de la varianza de la ecuación (6).

$$B^2 = k^2 \text{Var}(\hat{\mu}_{m.a.s.}) \quad (7)$$

$$\frac{B^2}{k^2} = \sum_{h=1}^L \left( \frac{W_h^2}{n_h} - \frac{W_h^2}{N_h} \right) \sigma_h^{*2} \quad (8)$$

$$\frac{B^2}{k^2} = \sum_{h=1}^L \left( \frac{W_h^2}{n * w_h} - \frac{W_h^2}{N_h} \right) \sigma_h^{*2} \quad (9)$$

$$\frac{B^2}{k^2} + \sum_{h=1}^L \frac{W_h^2}{N_h} \sigma_h^{*2} = \sum_{h=1}^L \frac{W_h^2}{n * w_h} \sigma_h^{*2} \quad (10)$$

$$n = \frac{\sum_{h=1}^L \frac{W_h^2}{w_h} \sigma_h^{*2}}{\frac{B^2}{k^2} + \sum_{h=1}^L \frac{W_h^2}{N_h} \sigma_h^{*2}} \quad (11)$$

$$n = \frac{\sum_{h=1}^L \frac{W_h^2}{w_h} \sigma_h^{*2}}{\frac{B^2}{Z_{1-\frac{\alpha}{2}}^2} + \sum_{h=1}^L \frac{W_h^2}{N_h} \sigma_h^{*2}} \quad (12)$$

### 3. Demostración para *m.a.s.* con reemplazamiento

Bajo la hipótesis de *muestreo aleatorio simple con reemplazamiento (m.a.s.con)*, a partir del cual se pretende obtener una aproximación lo más precisa posible de la media poblacional  $\mu$ , un buen estimador del total poblacional es  $\hat{T}_{m.a.s.con} = \sum_{h=1}^n \sum_{k \in s_h} \frac{y_k}{n_h} N_h$ . Para el caso del estimador de la proporción poblacional, un buen estimador es  $\hat{\mu}_{m.a.s.con} = \frac{\hat{T}_{m.a.s.con}}{N}$ .

En las ecuaciones (13) y (14) se definen respectivamente las varianzas del estimador del total poblacional  $\hat{T}$  así como la proporción poblacional  $\hat{\mu}$ .

$$Var(\hat{T}_{m.a.s.con}) = \sum_{h=1}^L \frac{N_h^2 \sigma_h^2}{n_h} \quad (13)$$

$$\begin{aligned} Var(\hat{\mu}_{m.a.s.con}) &= \\ &= Var\left(\frac{\hat{T}_{m.a.s.con}}{N}\right) \\ &= \frac{Var(\hat{T}_{m.a.s.con})}{N^2} \\ &= \frac{\sum_{h=1}^L \frac{N_h^2 \sigma_h^2}{n_h}}{N^2} \\ &= \sum_{h=1}^L \frac{W_h^2 \sigma_h^2}{n_h} \end{aligned} \quad (14)$$

Para llegar a la expresión que relacione el tamaño de la muestra global  $n$  con el error de estimación  $B$  a un nivel de confianza  $(1 - \alpha)$ , definiremos  $k = Z_{1-\alpha/2}$ , siendo  $Z_{1-\alpha/2}$  el valor crítico  $(1 - \alpha/2)$  de la *distribución normal estándar*  $N(0, 1)$ . Además, nos apoyaremos en la ecuación (4) y la estimación de la varianza de la ecuación (6).

$$B^2 = k^2 Var(\hat{\mu}_{m.a.s.con}) \quad (15)$$

$$\frac{B^2}{k^2} = \sum_{h=1}^L \frac{W_h^2 \sigma_h^2}{n_h} \quad (16)$$

$$\frac{B^2}{k^2} = \sum_{h=1}^L \frac{W_h^2 \sigma_h^2}{n * w_h} \quad (17)$$

$$n = \sum_{h=1}^L \frac{W_h^2 \sigma_h^2}{B^2 * w_h} k^2 \quad (18)$$

$$n = \sum_{h=1}^L \frac{W_h^2 \sigma_h^2}{B^2 * w_h} \left(Z_{1-\frac{\alpha}{2}}\right)^2 \quad (19)$$

## Referencias

- [1] SÄRNDAL, C.-E., SWENSSON, B., AND WRETMAN, J. *Model assisted survey sampling*. Springer Science & Business Media, 2003.
- [2] TAPIA GARCÍA, J. A. Muestreo Estadístico 1, 2017/18. Facultad de Ciencias: Departamento de Estadística.